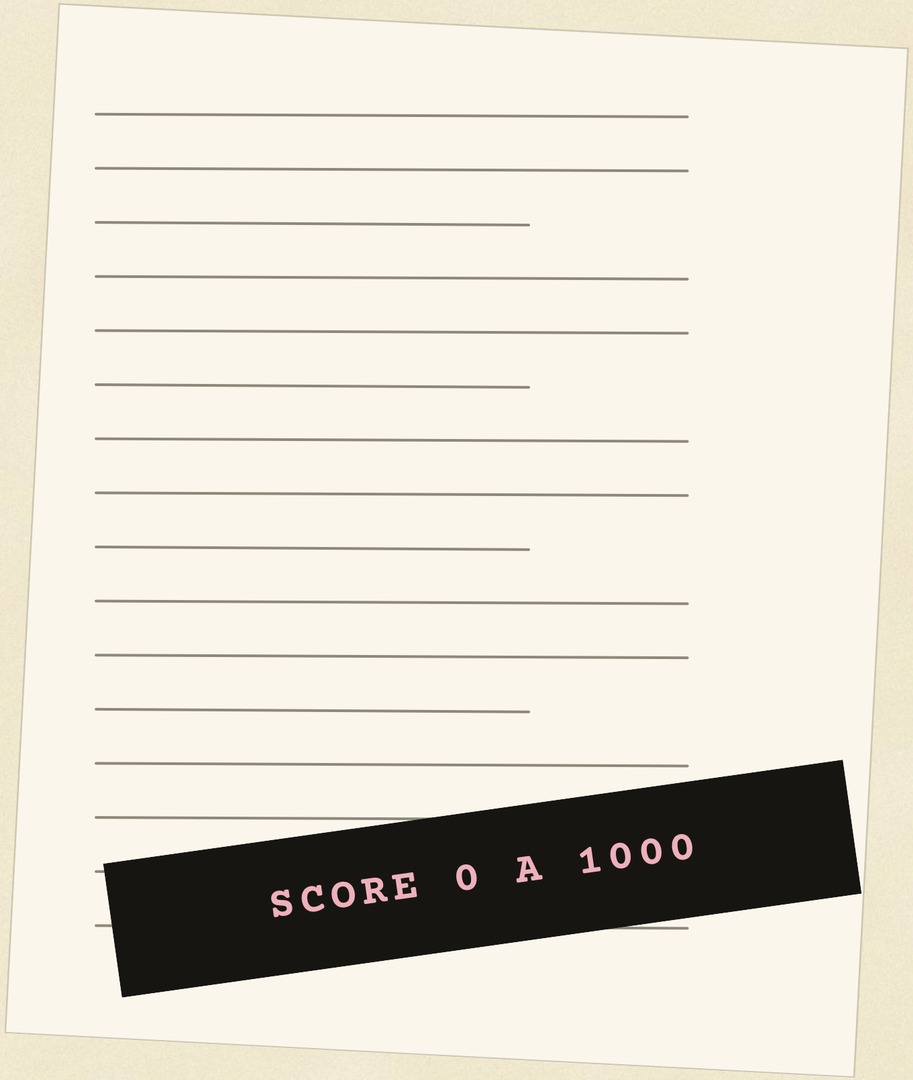
MODELO DE RISCO DE CRÉDITO



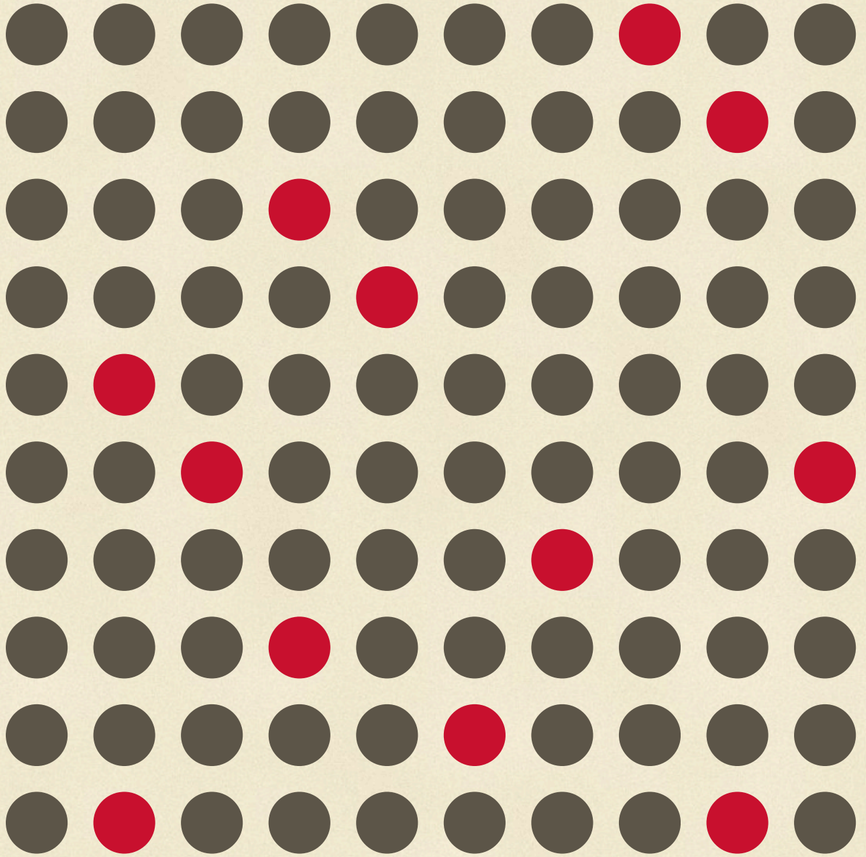
Case Modelagem de Riscos · Sicoob
Rayssa Lorrane · Outubro de 2026

O desafio: prever quem vai dar problema

10.000 clientes
8 informações sobre cada um (v1 a v8, com nomes anônimos)

TARGET = 1
o evento de risco (por exemplo, inadimplência). Chamamos esses clientes de “maus”; os demais, de “bons”.

Objetivo: dar a cada cliente uma nota de risco antes da decisão de crédito.



≈ 12 em cada 100 têm TARGET = 1 (11,5%)

Estudar com uma parte, fazer a prova com outra

7.000

TREINO · 70%

Clientes que o modelo usa para aprender os padrões.

3.000

TESTE · 30%

Clientes que o modelo nunca viu. É a “prova final”.

SEM COLA

As duas partes têm a mesma proporção de TARGET = 1 (11,5%). Assim, a prova é justa: parecida com o mundo real, mas com questões novas.

Todos os resultados desta apresentação são da prova (amostra de teste).

O que mais diferencia os clientes

ALERTA MÁXIMO

V5 / V6 MAIOR QUE ZERO

73%

têm TARGET = 1, contra 8% dos demais. Atinge só 4,8% dos clientes.

PROTEÇÃO

V8 ALTO (ACIMA DE 1.410)

2,1%

de TARGET. Quando v8 é zero, a taxa sobe para 21,8%.

ALERTA

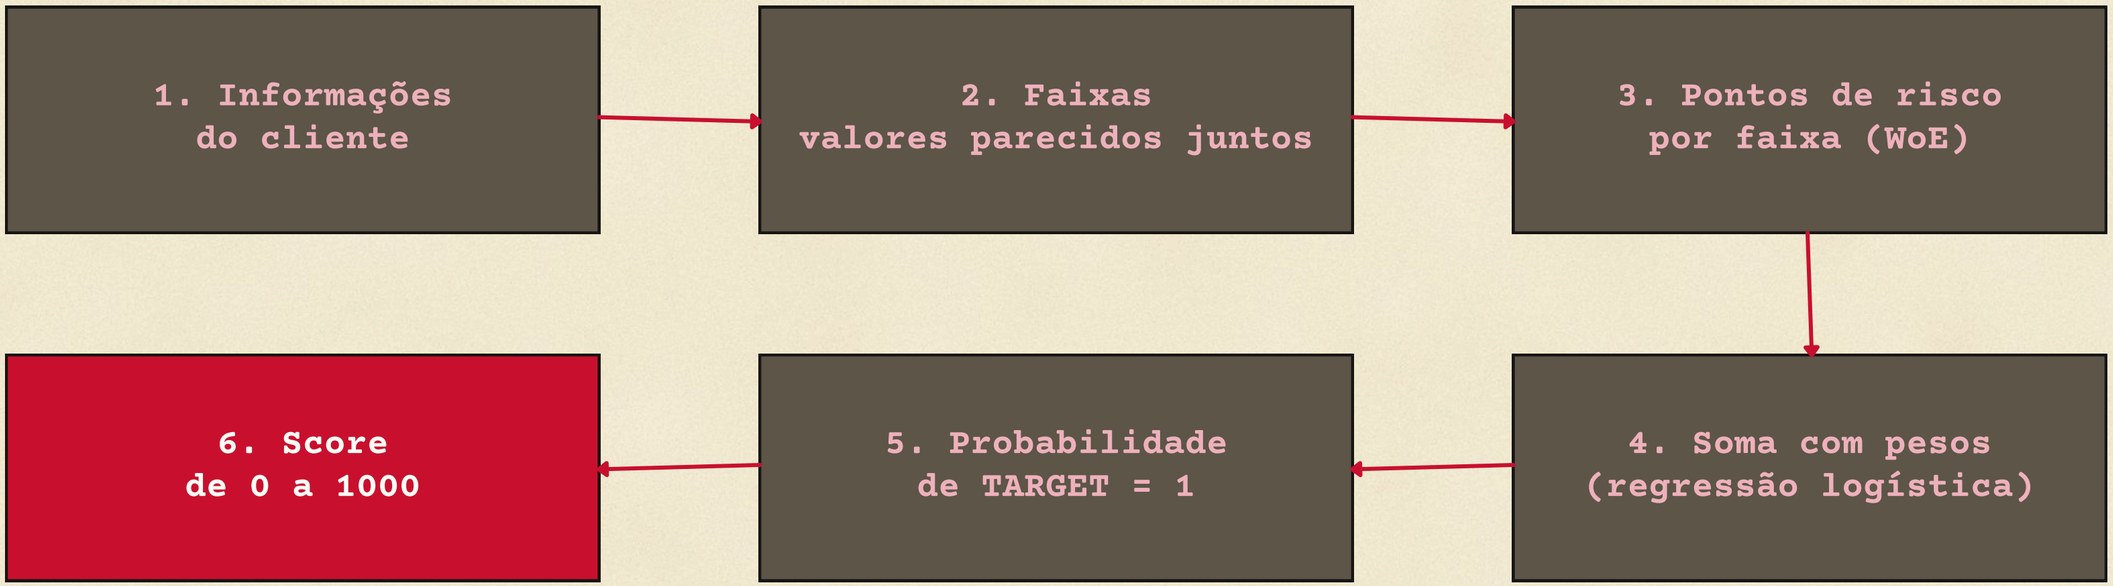
V7 ALTO (ACIMA DE 853)

14,1%

de TARGET. Quando v7 é zero, a taxa cai para 2,8%.

v2, v4 e v1 têm efeito menor, mas ajudam a refinar a nota. Os nomes são anônimos: “atraso”, “saldo” ou “dívida” são hipóteses de leitura.

Como o modelo chega à nota



Funciona como um checklist de pontos: cada faixa de cada variável vale uma quantidade de risco, e o modelo soma tudo com pesos. Por isso dá para explicar a nota de qualquer cliente.

Dois candidatos, um escolhido

ESCOLHIDO

Regressão logística

COMO DECIDE

Soma pontos de cada faixa (scorecard)

DÁ PARA EXPLICAR?

Sim: cada variável tem um peso claro

NOTA NA PROVA (AUC)

0,807

COMPARAÇÃO

Random Forest

COMO DECIDE

500 árvores de decisão votam juntas

DÁ PARA EXPLICAR?

Pouco: funciona como caixa-preta

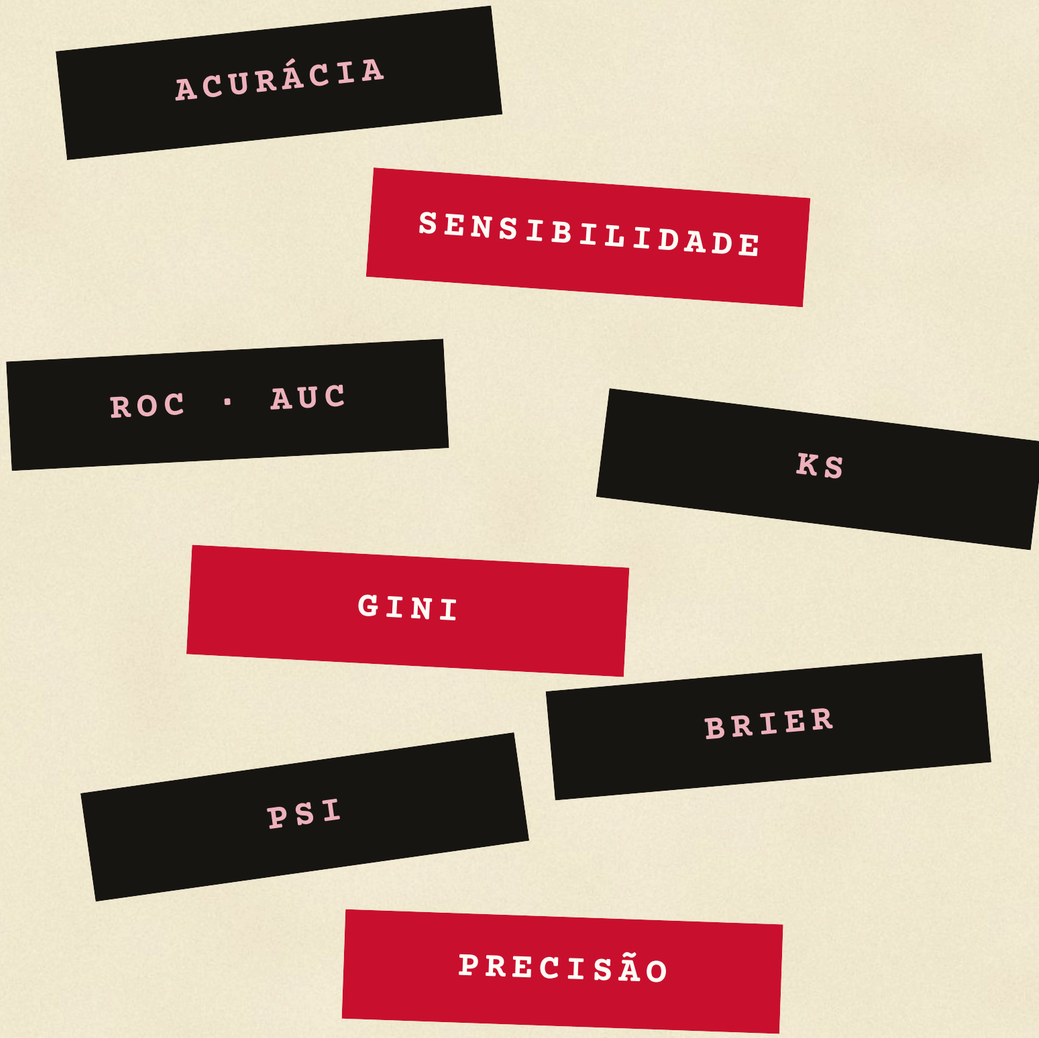
NOTA NA PROVA (AUC)

0,803

Mesmo desempenho. Em crédito, explicar a decisão ao cliente e à auditoria vale mais.

Como saber se o modelo é bom?

As métricas, explicadas sem fórmula.



Os quatro resultados possíveis

Matriz de confusão · 3.000 clientes da prova · risco alto = probabilidade ≥ 12,3% (score ≤ 877)

	MODELO DISSE: RISCO ALTO	MODELO DISSE: RISCO BAIXO
ERAM MAUS	**262** — MAUS DETECTADOS — acerto	**83** — MAUS QUE PASSARAM — erro caro: o crédito vira prejuízo
ERAM BONS	**777** — BONS BARRADOS — erro de oportunidade: perde um bom cliente	**1.878** — BONS APROVADOS — acerto

Todo modelo erra para os dois lados. Quantos clientes barrar depende de quanto custa cada tipo de erro.

Acurácia: o % de acertos, e sua armadilha

71,3%

ACURÁCIA

O modelo acerta o grupo de 71 em cada 100 clientes da prova: (262 + 1.878) ÷ 3.000.

ARMADILHA

UM "MODELO" QUE APROVA TODO MUNDO

88,5%

de acurácia, porque 88,5% dos clientes são bons. Mas ele não encontra nenhum mau pagador.

Quando o evento é raro, acurácia alta pode não significar nada. Por isso, em risco de crédito, olhamos sensibilidade, AUC e KS.

Quem o modelo pega, e quem ele barra

75,9%

SENSIBILIDADE

Dos maus pagadores, o modelo pega 3 em cada 4 (262 de 345).

70,7%

ESPECIFICIDADE

Dos bons pagadores, aprova 7 em cada 10 (1.878 de 2.655).

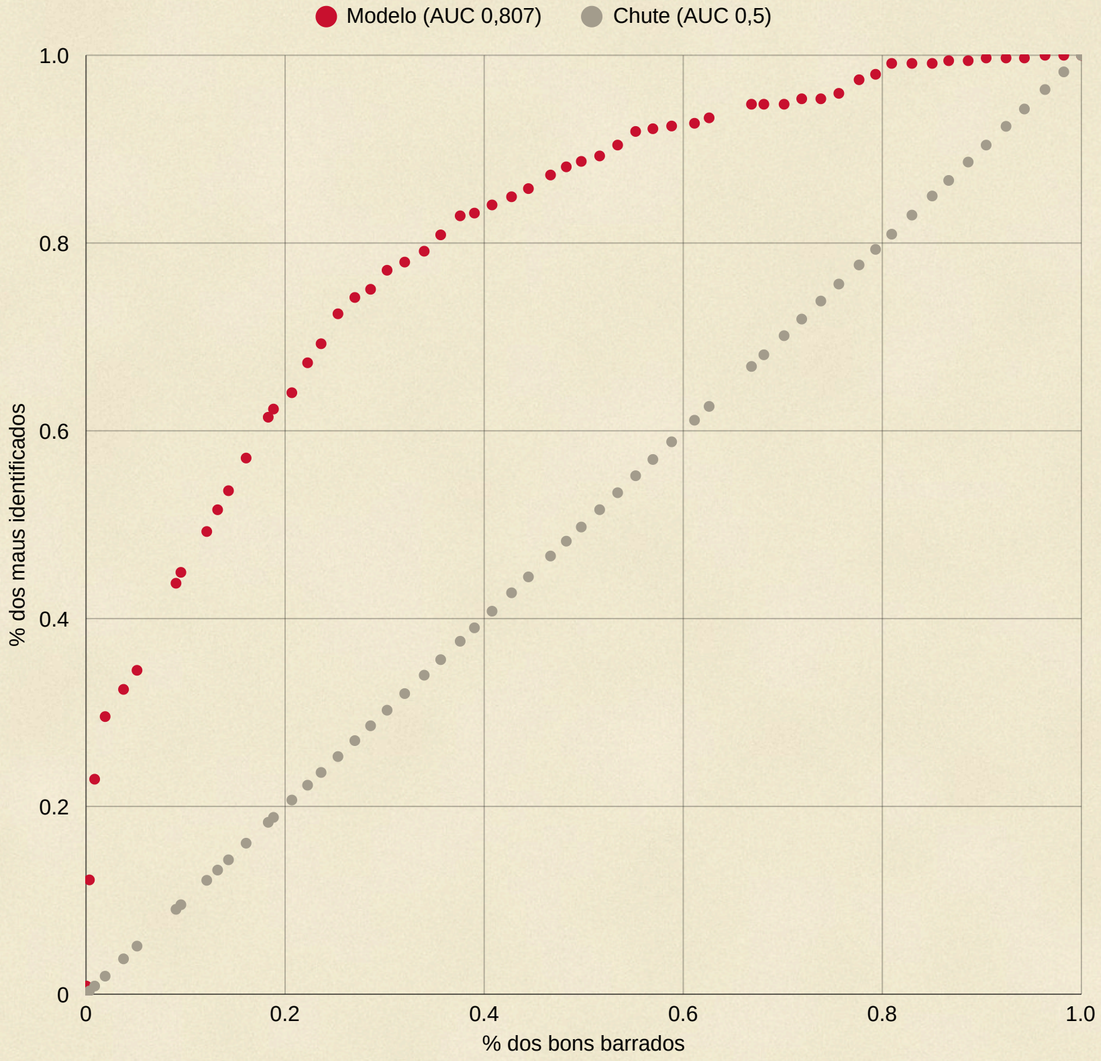
25,2%

PRECISÃO

Dos barrados, 1 em cada 4 é mau: 2,2 vezes a média de 11,5%.

É uma gangorra. Um corte mais rigoroso pega mais maus (sensibilidade sobe), mas barra mais bons (especificidade cai). O ponto certo depende do custo de cada erro para o negócio.

ROC e AUC: o modelo ordena bem o risco?



0,807

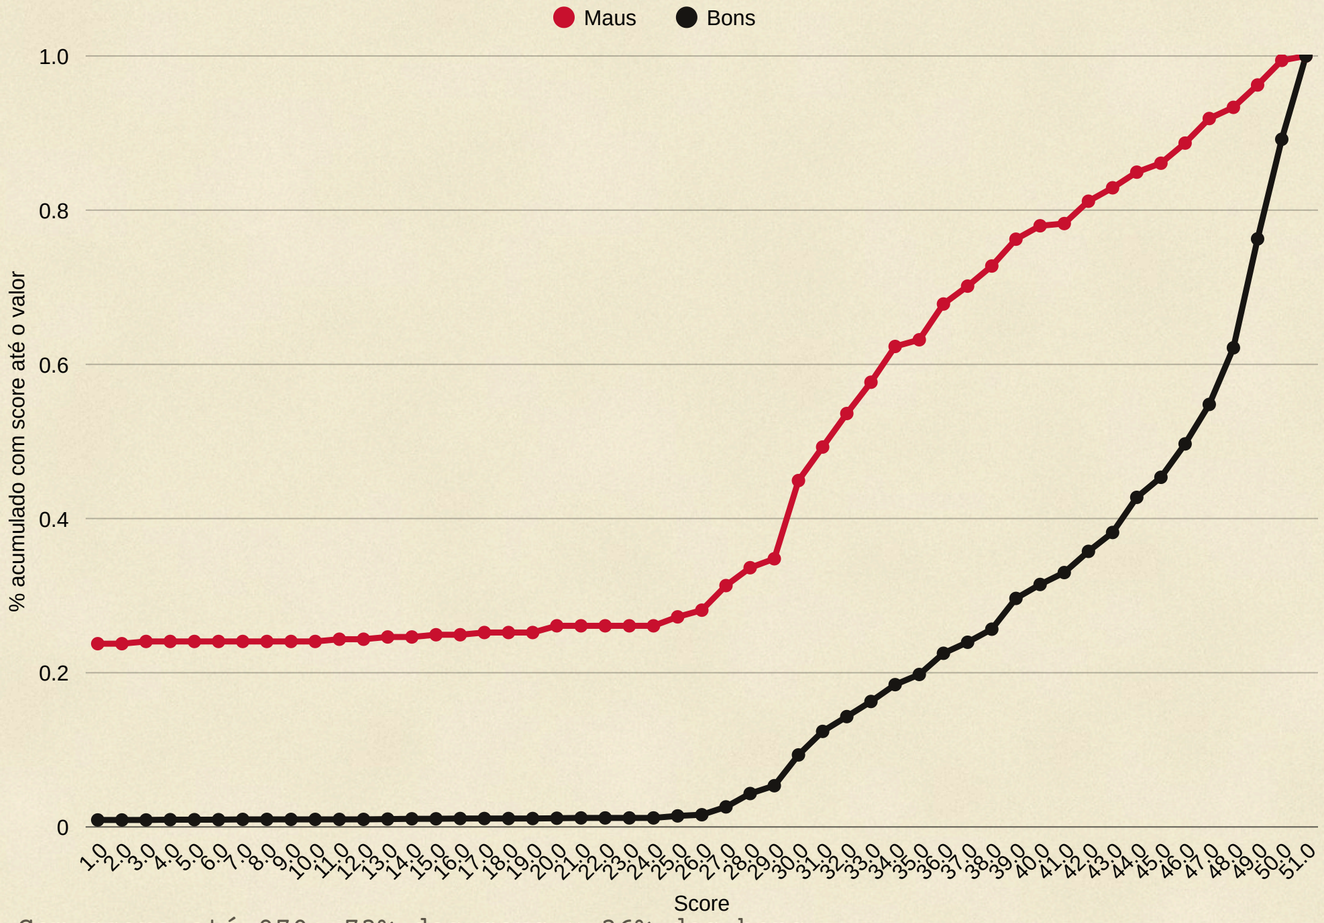
AUC (ÁREA SOB A CURVA ROC)

Sorteie um mau e um bom pagador: em 81% das vezes, o modelo dá risco maior ao mau.

A curva ROC mostra todos os cortes possíveis. Quanto mais ela “sobe pela esquerda”, melhor o modelo separa.



KS e Gini: quanto o modelo separa bons de maus



Com score até 870: 73% dos maus × 26% dos bons

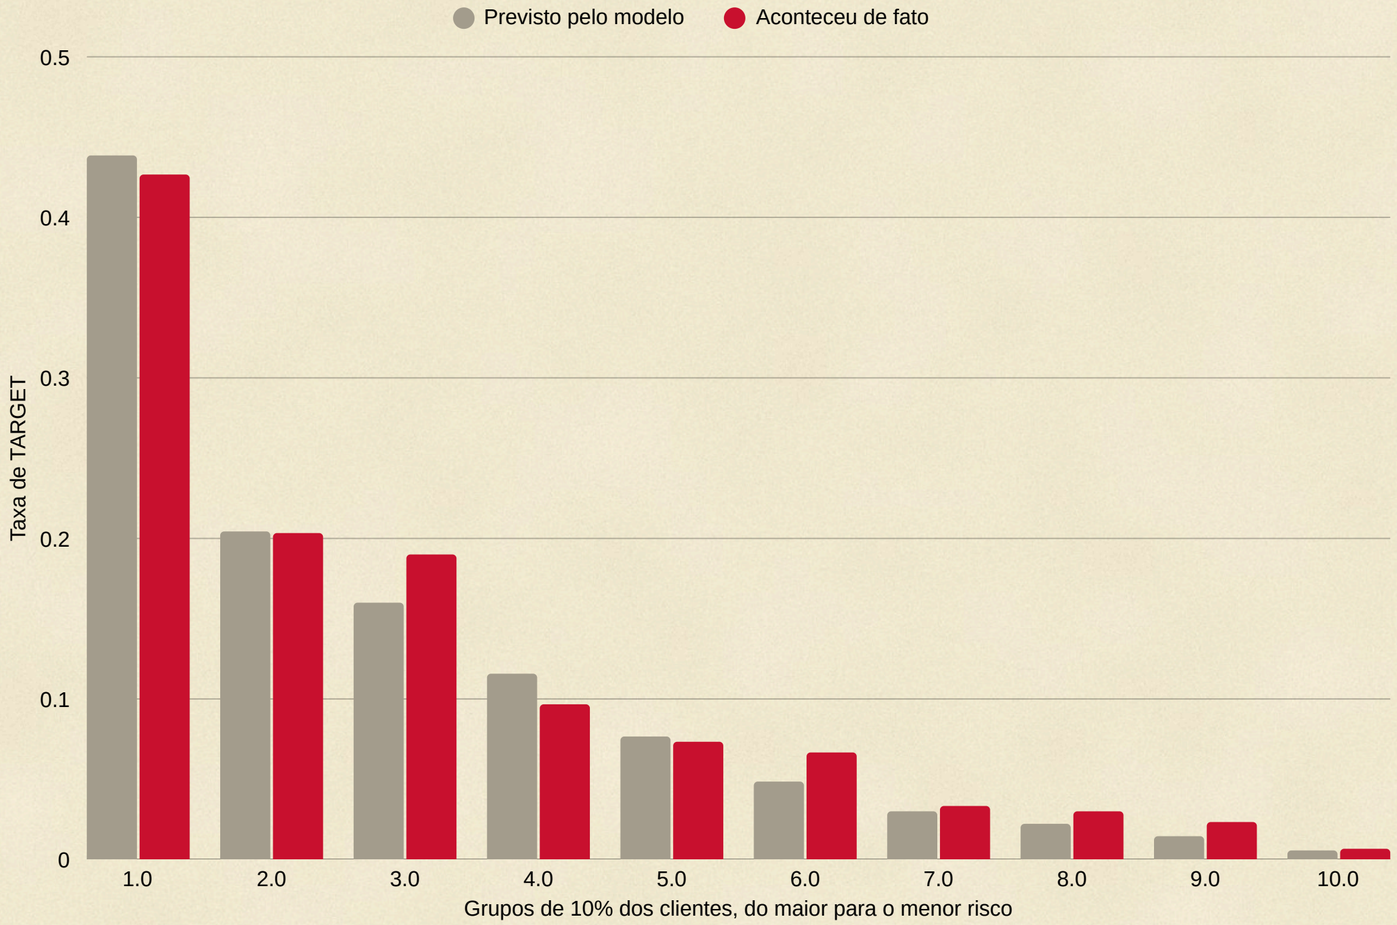
47,2 KS

A maior distância entre as duas curvas, em pontos. 0 = não separa nada; 100 = separa todos. Em crédito, acima de 40 costuma ser considerado bom.

0,613 GINI

É a AUC em outra escala: 2 × AUC − 1. Vai de 0 (chute) a 1 (perfeito).

Brier: dá para confiar no percentual?



0,080

BRIER

O erro médio entre a probabilidade prevista e o que aconteceu. Quanto menor, melhor (0 = perfeito).

Chutar 11,5% para todo mundo daria 0,102. O modelo erra menos.

Calibração: no grupo de maior risco, o modelo previu 43,9% e aconteceram 42,7%.

O modelo é estável ou só decorou?

0,827 ↛ 0,807

TREINO → PROVA (AUC)

A nota cai pouco ao trocar de dados: o modelo aprendeu padrões, não decorou respostas.

0,80 a 0,84

5 PROVAS DIFERENTES

Validação cruzada: o modelo foi treinado e testado 5 vezes, em partes diferentes. A AUC ficou sempre nessa faixa.

0,003

PSI

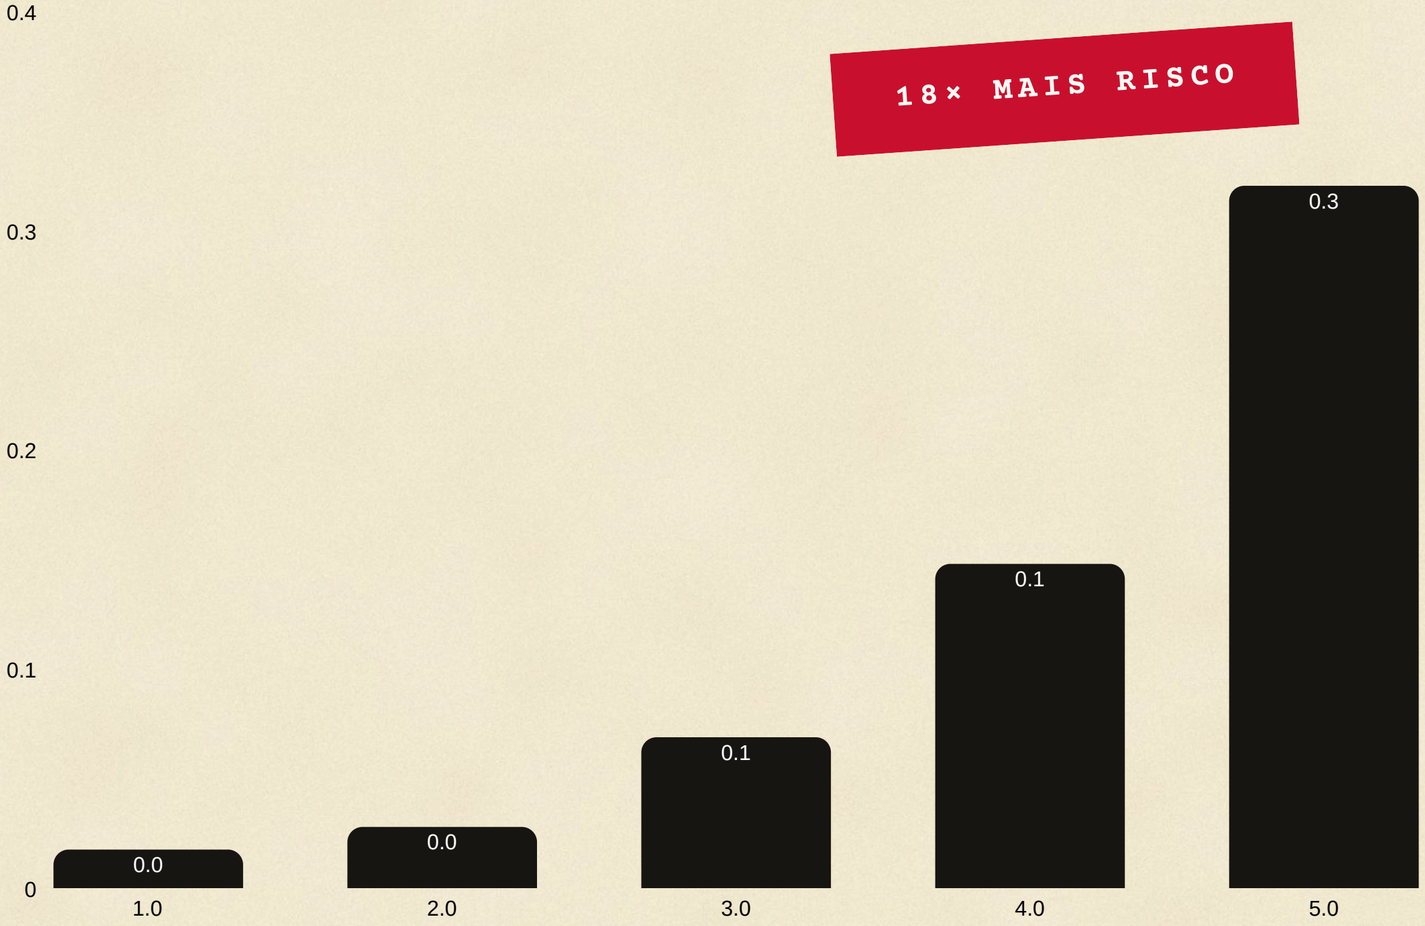
Mede se a distribuição dos scores mudou entre treino e prova. Abaixo de 0,10 = estável.

ESTÁVEL

Cola: cada métrica em uma frase

MÉTRICA	PERGUNTA QUE RESPONDE	RESULTADO	LEITURA
Acurácia	Quantos o modelo acertou?	**71,3%**	Engana quando o evento é raro
Sensibilidade	Dos maus, quantos ele pegou?	**75,9%**	3 em cada 4
Precisão	Dos barrados, quantos eram maus?	**25,2%**	2,2× a taxa média
AUC	Ele ordena bem o risco?	**0,807**	Bom (0,5 = chute)
Gini	A AUC em outra escala	**0,613**	Bom (0 = chute)
KS	Quanto separa bons de maus?	**47,2**	Bom (acima de 40)
Brier	As probabilidades são honestas?	**0,080**	Melhor que chutar (0,102)
PSI	O comportamento ficou estável?	**0,003**	Estável (abaixo de 0,10)

Do score à decisão: cinco faixas de risco



RECUSAR SÓ A FAIXA E

19% dos clientes

54% dos maus evitados

RESTRINGIR D E E

39% dos clientes

79% dos maus evitados

Faixa A: score 982 a 998 · Faixa E: score até 813 · cerca de 20% dos clientes em cada faixa

Limitações & próximos passos

LIMITAÇÕES

× Variáveis anônimas: as leituras de negócio são hipóteses.
× Sem datas: não foi possível testar em um período futuro.
× Boa parte do poder vem de v5/v6, que atinge só 4,8% dos clientes.
× O corte ideal depende de custos que a base não traz.

PRÓXIMOS PASSOS

✓ Validar com clientes de um período mais recente.
✓ Definir o corte com perda esperada e margem por faixa.
✓ Acompanhar o PSI todo mês.
✓ Testar um modelo desafiante (gradient boosting).

Ordenar o risco.
Explicar a decisão.
Monitorar sempre.



Código e documentação: github.com/rayssalorrane/case-modelagem-riscos