[Case] Modelagem de Riscos – Modelo preditivo do TARGET

Resumo executivo

O modelo escolhido é uma regressão logística com variáveis em WoE (scorecard). Na amostra de teste ela atinge AUC de 0,807, Gini de 0,613 e KS de 47,2, com desempenho igual ou melhor que o de um Random Forest e com a vantagem de ser interpretável.

Indicador	Resultado
Base	10.000 clientes, 8 variáveis (v1–v8), TARGET = 11,5%
Modelo final	Regressão logística com 6 variáveis em WoE: v5, v8, v7, v2, v4 e v1
AUC / Gini / KS (teste)	0,807 / 0,613 / 47,2
Validação cruzada (5 folds)	AUC 0,823 ± 0,019
Estabilidade (PSI treino × teste)	0,003 (estável)
Ordenação	10% de maior risco: 42,7% de TARGET (3,7× a média)

- Variáveis mais importantes:
  - v5/v6 maior que zero (4,8% dos clientes): 73% deles têm TARGET = 1, contra 8% dos demais;
  - v8, onde valores maiores indicam risco menor;
  - v7, onde valores maiores indicam risco maior.
- Uso no negócio: a faixa de risco E tem 32% de TARGET e a faixa A tem 1,8%, uma separação de 18 vezes entre os extremos.

Base de dados e análise descritiva

- Tamanho: a base tem 10.000 clientes e 1.150 deles têm TARGET = 1 (11,5%).
- Qualidade: não há valores ausentes. Há uma linha duplicada, que foi mantida porque não há identificador para saber se é um erro.
- Variáveis: são anônimas (v1–v8). A estrutura de cada uma foi deduzida dos próprios dados.

Variável	Estrutura observada	% zeros	Mediana	TARGET no menor risco × maior risco	IV
v5	Contagem de 0 a 12 em escala log ($230{,}82 \times \log_2(1+k)$)	95,4%	0	8,4% (= 0) × 73,0% (> 0)	0,970
v6	Contínua, maior que zero exatamente nos mesmos clientes de v5	95,4%	0	8,4% (= 0) × 73,0% (> 0)	0,970
v8	Contínua	39,0%	639	2,1% (> 1.410) × 21,8% (= 0)	0,893
v7	Contínua	14,6%	913	2,8% (= 0) × 14,1% (> 853)	0,280
v2	Inteira, de 6 a 117 (possivelmente idade)	0%	43	5,8% (> 64) × 14,8% (≤ 27)	0,071
v3	Categórica (1, 2, 3)	0%	2	9,9% (2 ou 3) × 14,2% (1)	0,041
v4	Contínua	0,02%	1.725	7,2% (> 2.070) × 13,1% (≤ 1.540)	0,034
v1	Contagem de 0 a 8 em escala log ($\ln(1+k)$)	74,9%	0	9,0% (> 0) × 12,3% (= 0)	0,021

As taxas e o IV foram calculados na amostra de treino, a partir das faixas da seção de técnicas.

Leitura

- v5 e v6 formam o sinal mais forte: os 4,8% de clientes com valor maior que zero têm quase 9 vezes mais TARGET que os demais. O comportamento é compatível com um histórico de atraso, em que v5 seria a quantidade e v6 o valor.
- v8 e v7 têm sentidos opostos. Mais v8 indica menos risco, e mais v7 indica mais risco.
- v2, v3, v4 e v1 têm poder fraco, mas no mesmo sentido: clientes com valores mais altos têm risco menor.
- v5 e v6 têm correlação de 0,93 entre si. Nenhuma outra dupla passa de 0,42.

Preparação dos dados

1. Treino e teste: a base foi dividida em 70% para treino (7.000) e 30% para teste (3.000), estratificada pelo TARGET (11,5% nas duas). Tudo que o modelo aprende — faixas, WoE, coeficientes e pontos de corte — vem só do treino. O teste é usado apenas para medir o desempenho.
2. Faixas (binning): cada variável foi dividida em até 10 faixas por quantis, ou uma faixa por valor quando há poucos valores. Depois as faixas vizinhas foram unidas até duas condições valerem:
    - a taxa de TARGET sobe ou desce sempre no mesmo sentido (monotonicidade), o que deixa o modelo estável e explicável para o negócio;
    - toda faixa tem pelo menos 2% dos clientes.
3. Por que 2% e não os 5% usuais: com 5%, o grupo com v5/v6 maior que zero (4,8% dos clientes, 73% de TARGET) seria unido aos zeros, e a variável mais forte da base perderia todo o seu poder.
4. WoE: cada faixa foi substituída pelo seu WoE (Weight of Evidence), que vale ln(% de bons na faixa ÷ % de maus na faixa).
5. Outliers: não foram excluídos nem truncados. O binning já coloca valores extremos (por exemplo, v2 = 6 ou v2 = 117) na faixa da ponta, então eles não distorcem o modelo.
6. Transformações: v1 e v5 já vêm em escala logarítmica (de contagens). Nenhuma outra transformação foi necessária, porque o WoE já captura relações não lineares.

Técnicas utilizadas

Foram comparados dois modelos: uma regressão logística sobre variáveis em WoE, o padrão de mercado para scorecards de risco, e um Random Forest como referência de um modelo mais flexível.

	Regressão logística (WoE) — escolhido	Random Forest — comparação
Por que usar	Padrão em modelagem de crédito: cada variável tem um peso claro e cada faixa vira pontos de score	Captura não linearidades e interações sem precisar de faixas
Entradas	6 variáveis em WoE	As 8 variáveis originais
Interpretação	Coeficientes, razões de chance e scorecard	Importância por permutação (sem sentido do efeito)
Configuração	glm binomial	500 árvores, mtry = 3, nó mínimo de 50
AUC no teste	0,807	0,803

Seleção de variáveis da logística, em ordem:

1. IV mínimo: IV ≥ 0,02. As 8 variáveis passaram.
2. Correlação: entre variáveis com correlação acima de 0,7 em WoE, fica a de maior IV. A v6 saiu, porque é redundante com a v5.
3. Sinal e significância: o coeficiente precisa ter o sinal esperado e p-valor < 0,05. A pior variável sai e o modelo é reajustado. A v3 saiu, porque perdeu significância depois que v5 e v8 entraram.
4. Multicolinearidade: o VIF das variáveis finais ficou abaixo de 1,07, ou seja, sem colinearidade.

Como o desempenho foi medido:

- AUC e Gini: medem a capacidade de ordenar clientes por risco.
- KS: a maior separação entre as distribuições de bons e maus.
- Brier: o erro das probabilidades previstas.
- Matriz de confusão: acertos e erros em um ponto de corte.
- Calibração por decil: a probabilidade prevista comparada com a taxa observada.
- PSI: a estabilidade da distribuição do score entre treino e teste.
- Validação cruzada em 5 folds: o binning é refeito dentro de cada fold, para não vazar informação.

Por que a logística foi a escolhida: ela empata ou supera o Random Forest no teste e na validação cruzada (AUC 0,823 contra 0,818), é transparente e é mais fácil de explicar, auditar e monitorar — requisitos importantes em risco de crédito.

Modelo estimado

O modelo final tem 6 variáveis, todas com p-valor < 0,01, sinal esperado e sem colinearidade.

$$logit(P(TARGET = 1)) = -2,054 - 0,920\,WoE_{v5} - 0,904\,WoE_{v8} - 0,878\,WoE_{v7} - 0,790\,WoE_{v2} - 0,8$$

Variável	Coeficiente	Erro padrão	p-valor	VIF	Faixa de menor risco	Faixa de maior risco	Razão de chance (pior ÷ melhor faixa)
v5	−0,920	0,042	< 0,001	1,03	= 0	> 0	**22,3×**
v8	−0,904	0,056	< 0,001	1,05	> 1.410	= 0	**10,1×**
v7	−0,878	0,109	< 0,001	1,03	= 0	> 853	4,6×
v2	−0,790	0,183	< 0,001	1,07	> 64	≤ 27	2,2×
v4	−0,898	0,265	< 0,001	1,07	> 2.070	≤ 1.540	1,8×
v1	−0,900	0,311	0,004	1,01	> 0	= 0	1,4×
Intercepto	−2,054	0,048	< 0,001	—	—	—	—

Como ler:

- Com o WoE definido como ln(bons ÷ maus), um coeficiente negativo é o esperado: WoE maior significa menos risco. Coeficientes perto de −1 indicam que o WoE de cada variável já está bem calibrado.
- A razão de chance mostra quantas vezes a chance de TARGET = 1 aumenta ao passar da melhor para a pior faixa da variável, com as demais fixas.

Interpretação:

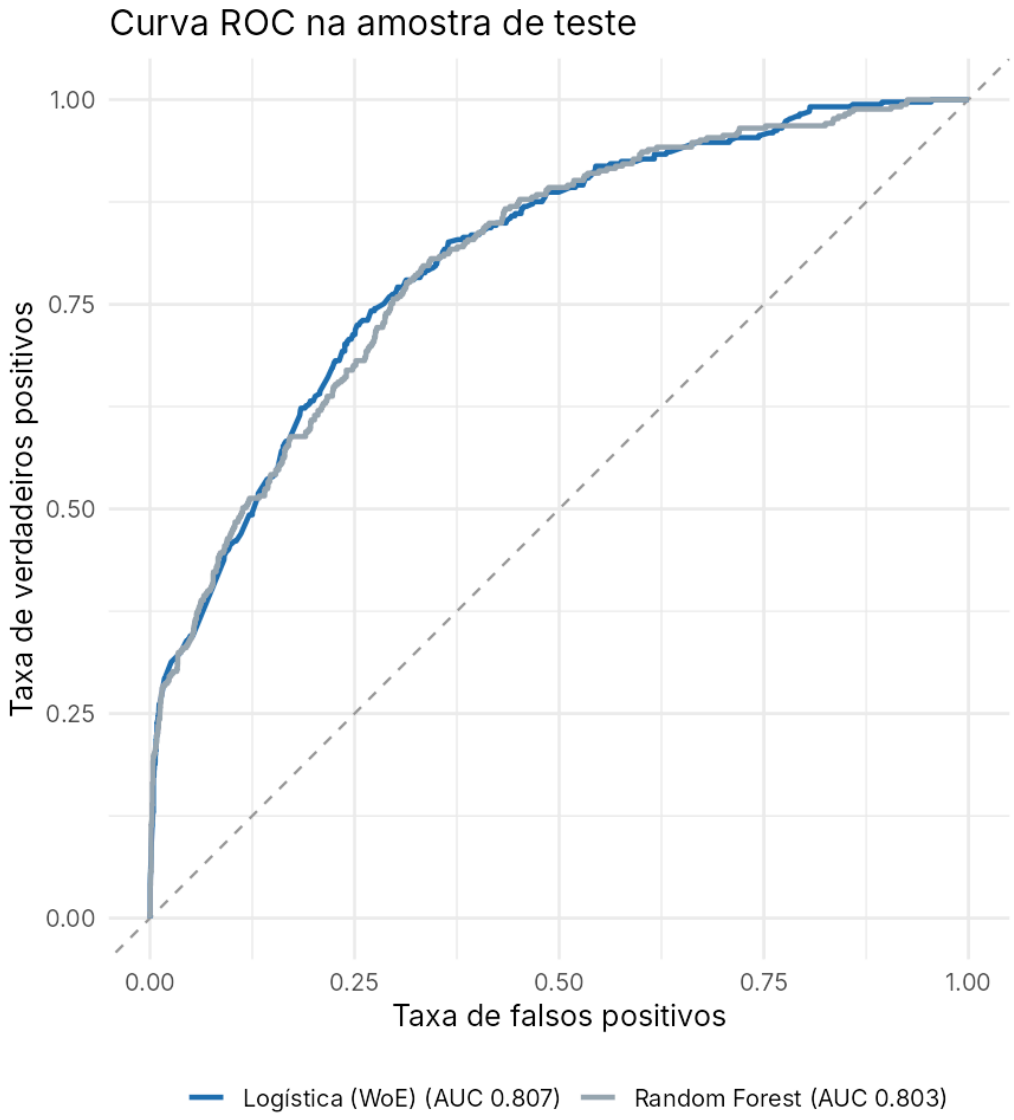
- v5 é o fator de maior peso: ter v5 maior que zero multiplica a chance de TARGET por 22. Esse é o comportamento típico de restrição ou atraso prévio.
- v8 é o principal fator de proteção: clientes com v8 = 0 têm 10 vezes mais chance que os de v8 alto. O padrão é compatível com reciprocidade, como saldo ou investimento.
- v7 age no sentido contrário: quanto maior, maior o risco. O padrão é compatível com endividamento ou uso de limite.
- v2, v4 e v1 refinam o score: clientes mais velhos (se v2 for idade), com v4 mais alto ou com v1 maior que zero têm risco um pouco menor.

Os nomes das variáveis são anônimos, então as associações com o negócio são hipóteses a confirmar com o dicionário de dados.

Métricas avaliadas

No teste, o modelo tem AUC de 0,807 e KS de 47,2, valores considerados bons para risco de crédito. A queda do treino para o teste é pequena (AUC de 0,827 para 0,807), o que indica ausência de sobreajuste relevante.

Modelo	Amostra	AUC	Gini	KS	Brier
Logística (WoE)	Treino	0,827	0,653	49,4	0,075
Logística (WoE)	Teste	0,807	0,613	47,2	0,080
Logística (WoE)	Validação cruzada (5 folds)	0,823 ± 0,019	—	49,8 ± 3,7	—
Random Forest	Treino (out-of-bag)	0,814	0,628	47,9	0,076
Random Forest	Teste	0,803	0,607	46,3	0,080
Random Forest	Validação cruzada (5 folds)	0,818 ± 0,018	—	50,0 ± 4,1	—



As duas curvas ROC quase se sobrepõem: o Random Forest, mais complexo, não traz ganho de discriminação sobre a logística.

Matriz de confusão no teste, com ponto de corte em P(TARGET) ≥ 12,3%. O corte foi escolhido no treino como o que maximiza o KS e equivale a um score ≤ 877.

	Previsto TARGET = 1	Previsto TARGET = 0
Real TARGET = 1	262 (verdadeiros positivos)	83 (falsos negativos)
Real TARGET = 0	777 (falsos positivos)	1.878 (verdadeiros negativos)

Nesse corte:

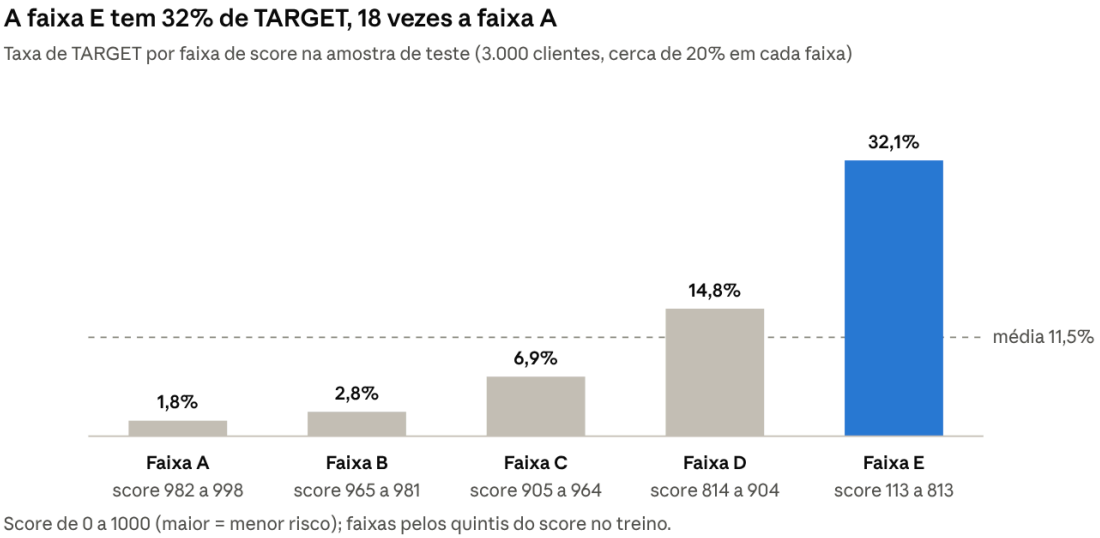
- o modelo sinaliza 34,6% dos clientes e captura 75,9% dos casos de TARGET = 1 (sensibilidade);
- aprova corretamente 70,7% dos bons (especificidade);
- a precisão é de 25,2%, ou seja, 2,2 vezes a taxa média de 11,5%;
- a acurácia é de 71,3%.

A acurácia não é a melhor métrica aqui: com 11,5% de TARGET, um modelo que aprovasse todos teria 88,5% de acurácia sem identificar nenhum mau. O corte ideal depende do custo de aprovar um mau comparado ao de recusar um bom, e deve ser definido com a área de negócio.

Estabilidade: o PSI do score entre treino e teste é 0,003, bem abaixo de 0,10, o limite usual de atenção.

Uso no negócio: score e faixas de risco

O score vai de 0 a 1000 e é calculado como 1000 × (1 − P(TARGET)): quanto maior, menor o risco. As faixas A a E foram definidas pelos quintis do score no treino e ordenam o risco de forma perfeita no teste: a taxa de TARGET sobe a cada faixa.



Amostra de teste (3.000 clientes) · output/resultados_modelo.xlsx, aba Faixas de risco

Faixa	Score	% dos clientes (teste)	Política sugerida
A	982 a 998	20,5%	Aprovação automática, limites maiores
B	965 a 981	18,9%	Aprovação automática
C	905 a 964	21,7%	Aprovação com limite padrão
D	814 a 904	19,6%	Análise manual, limite reduzido ou garantia
E	até 813	19,3%	Recusa ou exigência de garantia

Impacto de políticas de corte:

- Recusar só a faixa E afeta 19% dos clientes e evita 54% dos casos de TARGET = 1 (186 de 345 no teste).
- Tratar D e E com restrição afeta 39% dos clientes e cobre 79% dos casos.

Os 10% de clientes com maior risco têm 42,7% de TARGET, 3,7 vezes a média. A probabilidade prevista para eles (43,9%) é quase igual à observada, o que mostra que o modelo está bem calibrado.

Limitações e próximos passos

Limitações:

- Variáveis anônimas: a leitura de negócio (atraso, saldo, endividamento, idade) é uma hipótese. Com o dicionário de dados, as faixas podem ser revisadas com critério de negócio.
- Sem dimensão de tempo: a base não tem data, então não foi possível fazer uma validação fora do tempo (out-of-time). O teste e a validação cruzada são da mesma população.
- Concentração do poder: boa parte do poder vem de v5/v6, que atinge só 4,8% dos clientes. Para os outros 95%, o modelo depende de v8 e v7.
- Ponto de corte: o corte apresentado maximiza o KS. Um corte de negócio precisa de custos e receitas por cliente, que a base não traz.

Próximos passos:

1. Validar o modelo em uma safra mais recente (out-of-time) e acompanhar o PSI mensalmente.
2. Definir o ponto de corte por faixa com base em perda esperada e margem.
3. Testar interações (por exemplo, v7 × v8) e um modelo de gradient boosting como desafiante.
4. Revisar as faixas com o dicionário de dados e com a área de crédito.

Código: todo o processo está no script em R scripts/modelo_risco.R, enviado também como codigo_modelo_risco.txt. O repositório fica em github.com/rayssalorrane/case-modelagem-riscos. Para reproduzir, basta rodar o script com a mesma semente (2026).